

TP2 – Droites de régression

Exercice 1 : estimation de D_{YX} par maximum de vraisemblance

Lancez le script `donnees.m`, qui affiche n points $P_i = (x_i, y_i)$ du plan censés être alignés. En utilisant l'équation paramétrique $y = ax + b$ d'une droite et en notant $r_{a,b}(P_i) = y_i - ax_i - b$ le résidu de cette équation pour le point P_i , il est légitime de modéliser ces résidus par une loi normale centrée :

$$f_{a,b}(P_i) = \frac{1}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{r_{a,b}(P_i)^2}{2\sigma^2} \right\} \quad (1)$$

La *droite de régression de Y en X* d'un tel nuage de points, notée D_{YX} , est la droite d'équation paramétrique $y = a^*x + b^*$, où a^* et b^* sont les valeurs des paramètres a et b qui maximisent la log-vraisemblance :

$$(a^*, b^*) = \arg \max_{(a,b) \in \mathbb{R}^2} \left\{ \ln \left[\prod_{i=1}^n f_{a,b}(P_i) \right] \right\} = \arg \min_{(a,b) \in \mathbb{R}^2} \left\{ n \ln \sigma + \frac{1}{2\sigma^2} \sum_{i=1}^n r_{a,b}(P_i)^2 \right\} \quad (2)$$

Si l'on suppose l'écart-type du bruit σ fixé, alors le problème se simplifie :

$$(a^*, b^*) = \arg \min_{(a,b) \in \mathbb{R}^2} \left\{ \sum_{i=1}^n r_{a,b}(P_i)^2 \right\} = \arg \min_{(a,b) \in \mathbb{R}^2} \left\{ \sum_{i=1}^n (y_i - ax_i - b)^2 \right\} \quad (3)$$

La résolution de (3) par tirages aléatoires n'est pas aussi simple qu'il y paraît, car les inconnues a et b ne sont pas bornées et a ne suit pas une loi uniforme. Néanmoins, il est facile de montrer que D_{YX} contient le centre de gravité G . On peut donc calculer les coordonnées (x_G, y_G) de G , puis centrer les données. Comme l'équation de D_{YX} devient $y' = a^*x'$ après changement d'origine, le problème (3) se simplifie encore :

$$a^* = \arg \min_{a \in \mathbb{R}} \left\{ \sum_{i=1}^n (y'_i - ax'_i)^2 \right\} = \tan \left[\arg \min_{\psi \in]-\frac{\pi}{2}, \frac{\pi}{2}[} \left\{ \sum_{i=1}^n (y'_i - \tan \psi x'_i)^2 \right\} \right] \quad (4)$$

Dans (4), la deuxième égalité vient de ce que le paramètre a d'une droite est égal à la tangente de son angle polaire ψ . La résolution de (4) peut être effectuée par tirages aléatoires de ψ , selon une loi uniforme sur $] -\frac{\pi}{2}, \frac{\pi}{2}[$.

Complétez le script `exercice_1.m` de façon à estimer ψ^* , puis les paramètres a^* et b^* , en suivant ce procédé.

Exercice 2 : estimation de D_{YX} par résolution d'un système linéaire

Le critère à minimiser dans (2) s'écrit $\mathcal{F}(\sigma, a, b) = n \ln \sigma + \frac{1}{2\sigma^2} \sum_{i=1}^n r_{a,b}(P_i)^2$. Le problème (2) peut donc également être considéré comme un problème d'optimisation différentiable. En notant $\mathcal{G}(a, b) = \sum_{i=1}^n r_{a,b}(P_i)^2$:

$$\nabla \mathcal{F}(\sigma, a, b) = 0 \iff \begin{cases} \nabla_{\sigma} \mathcal{F}(\sigma, a, b) = 0 \\ \nabla_{a,b} \mathcal{F}(\sigma, a, b) = 0 \end{cases} \iff \begin{cases} \sigma^2 = \frac{1}{n} \sum_{i=1}^n r_{a,b}(P_i)^2 \\ \nabla \mathcal{G}(a, b) = 0 \end{cases} \quad (5)$$

La première de ces équations était prévisible, puisque c'est la définition même de la variance. Quant à la deuxième équation, elle correspond à l'optimalité du critère à minimiser dans (3). Or, ce critère s'écrit aussi :

$$\mathcal{G}(a, b) = \|AX - B\|^2, \text{ avec } A = \begin{bmatrix} x_1 & \dots & x_n \\ 1 & \dots & 1 \end{bmatrix}^T, X = \begin{bmatrix} a \\ b \end{bmatrix} \text{ et } B = [y_1 \quad \dots \quad y_n]^T \quad (6)$$

Minimiser $\mathcal{G}(a, b)$ revient donc à chercher une solution approchée du système linéaire $AX = B$, au sens des *moindres carrés ordinaires*. Le problème se résout en écrivant les *équations normales* $A^T AX = A^T B$, dont la solution s'écrit $X^* = (A^T A)^{-1} A^T B = A^+ B$, où $A^+ = (A^T A)^{-1} A^T$ est la *matrice pseudo-inverse* de A (`pinv`).

Complétez le script `exercice_2.m` de manière à comparer cette méthode d'estimation de D_{YX} avec celle de l'exercice 1. Observez l'évolution des résultats lorsque la valeur de `nb_tirages` diminue. Testez également différentes valeurs du nombre $n \geq 2$ de données.

Exercice 3 : estimation de D_{\perp} par maximum de vraisemblance

Une droite D du plan peut également être définie par son *équation cartésienne normalisée* $x \cos \theta + y \sin \theta = \rho$:

- θ est l'angle polaire du vecteur \vec{v} orthogonal à D , de norme 1, tel que $\theta \in]0, \pi]$ (cf. figure 1).
- À partir d'un point $P = (x, y)$ quelconque de D , on peut calculer le second paramètre $\rho = x \cos \theta + y \sin \theta$.




FIGURE 1 – Les droites D_- et D_+ correspondent aux paramètres $(\theta, \rho_-) = (130, -1)$ et $(\theta, \rho_+) = (130, 1)$.

Si l'on désigne par $r_{\theta, \rho}(P_i) = x_i \cos \theta + y_i \sin \theta - \rho$ le résidu au point P_i de l'équation cartésienne normalisée, il semble à nouveau légitime de modéliser ces résidus par une loi normale centrée :

$$f_{\theta, \rho}(P_i) = \frac{1}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{r_{\theta, \rho}(P_i)^2}{2\sigma^2} \right\} \quad (7)$$

La *droite de régression en distance orthogonale* de ce nuage de points, notée D_{\perp} , est la droite d'équation $x \cos \theta^* + y \sin \theta^* = \rho^*$, où θ^* et ρ^* sont les valeurs des paramètres θ et ρ qui maximisent la log-vraisemblance :

$$(\theta^*, \rho^*) = \arg \max_{(\theta, \rho) \in]0, \pi] \times \mathbb{R}} \left\{ \ln \left[\prod_{i=1}^n f_{\theta, \rho}(P_i) \right] \right\} = \arg \min_{(\theta, \rho) \in]0, \pi] \times \mathbb{R}} \left\{ n \ln \sigma + \frac{1}{2\sigma^2} \sum_{i=1}^n r_{\theta, \rho}(P_i)^2 \right\} \quad (8)$$

En supposant σ fixé, et sachant que la droite de régression D_{\perp} contient elle aussi le centre de gravité G , la résolution du problème (8) est en tout point analogue à celle du problème (2). Par analogie avec (4) :

$$\theta^* = \arg \min_{\theta \in]0, \pi]} \left\{ \sum_{i=1}^n (x'_i \cos \theta + y'_i \sin \theta)^2 \right\} \quad (9)$$

Complétez le script `exercice_3.m` de manière à estimer les paramètres θ^* et ρ^* en suivant ce procédé.

Exercice 4 : estimation de D_{\perp} par résolution d'un système linéaire

Le critère $\mathcal{I}(\theta) = \sum_{i=1}^n (x'_i \cos \theta + y'_i \sin \theta)^2$ à minimiser dans (9) s'appelle l'*inertie*. Il s'écrit également :

$$\mathcal{I}(\theta) = \|CY\|^2, \text{ avec } C = \begin{bmatrix} x'_1 & \cdots & x'_n \\ y'_1 & \cdots & y'_n \end{bmatrix}^T \text{ et } Y = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \quad (10)$$

Or, la solution approchée du système linéaire $CY = O$, au sens des moindres carrés ordinaires, vaut $C^+O = O$. Pour éviter cette solution, on impose la contrainte $\|Y\| = 1$ (résolution approchée au sens des *moindres carrés totaux*). Ce nouveau problème se résout en introduisant le *lagrangien* $\mathcal{L}(Y, \lambda) = \|CY\|^2 + \lambda(1 - \|Y\|^2)$, où λ est un *multiplicateur de Lagrange*. La condition d'optimalité de \mathcal{L} s'écrit :

$$\nabla \mathcal{L}(Y, \lambda) = 0 \iff \begin{cases} \nabla_Y \mathcal{L}(Y, \lambda) = 0 \\ \nabla_{\lambda} \mathcal{L}(Y, \lambda) = 0 \end{cases} \iff \begin{cases} C^T CY = \lambda Y \\ \|Y\| = 1 \end{cases} \quad (11)$$

Sachant que $C^T C$ est symétrique réelle, cette matrice admet une base orthonormée de vecteurs propres associés à des valeurs propres ≥ 0 , car $C^T C$ est *semi-définie positive*. Le minimiseur de $\mathcal{I}(\theta)$ de norme 1, noté Y^* , est donc le vecteur propre associé à la plus petite valeur propre de $C^T C$. En effet, pour un vecteur propre Y_p de norme 1, associé à la valeur propre λ_p : $\|CY_p\|^2 = Y_p^T C^T CY_p = \lambda_p Y_p^T Y_p = \lambda_p$.

Complétez le script `exercice_4.m` de manière à comparer cette méthode d'estimation de D_{\perp} avec celle de l'exercice 3. Observez l'évolution des résultats pour différentes valeurs de `nb_tirages` et de `n`.

Enfin, affichez sur une même figure les droites de régression D_{YX} et D_{\perp} : que constatez-vous ?